

CICOS Claims Intelligence

RAG con evidencia verificable y decisión auditable
sobre el manual CIDE · ASCIDE · CICOS

111

páginas indexadas

110

casos golden

14

reglas firmadas

597

pruebas verdes

Cuarenta y cinco minutos, y un cuarto de ellos con el sistema delante.

La narración va de por qué este problema es más difícil de lo que parece, a cómo se demuestra que el sistema no improvisa.

01	El problema	Qué pide el enunciado y por qué cuatro de sus cinco accidentes no tienen respuesta determinista.	4 min
02	Plan, supuestos y riesgos	Cinco días con hitos comprobables, seis supuestos declarados y las decisiones técnicas con su porqué.	4 min
03	Arquitectura	Hexagonal, modelos, ingesta con cadena de custodia, recuperación híbrida, workflows y motor de reglas.	12 min
04	Demo en vivo	Cuatro recorridos sobre el sistema real: enrutado, caso resuelto, abstención y trazabilidad.	12 min
05	Evaluación y límites	Golden set de 110 casos, protocolo de medida, lo que el sistema no hace y la siguiente iteración.	6 min
06	Preguntas	Con el código, el manual, las trazas y el estado verificado delante.	7 min

La demo ocupa un cuarto del tiempo a propósito: lo que hay que creerse no son las láminas, es el sistema corriendo.

01

El problema

El enunciado parece pedir un buscador sobre un PDF.
Los cinco accidentes que adjunta piden otra cosa.

01 El problema

02 Plan y riesgos

03 Arquitectura

04 Demo en vivo

05 Evaluación y límites

El enunciado pide un RAG sobre el manual; los cinco accidentes que adjunta piden criterio.

Los dos encargos son reales, pero sólo el primero se resuelve con recuperación. El segundo exige aplicar un Convenio con reglas propias.

LO QUE PIDE EL ENUNCIADO

- **Un sistema RAG con un LLM**
sobre el manual de las comisiones CIDE, ASCIDE y CICOS.
- **Responder preguntas del manual**
y analizar relatos de accidentes: partes implicadas, responsabilidad y circunstancias de la colisión.
- **Una evaluación de la calidad**
de las respuestas, no una demostración anecdótica.
- **Plan, arquitectura y código**
con hitos, supuestos, riesgos y el porqué de cada decisión técnica.

LOS CINCO ACCIDENTES DE MUESTRA

- 1 Alcance en semáforo; ambos conductores dicen ir atentos.
- 2 Colisión múltiple con lluvia, cinco vehículos y heridos.
- 3 Vehículo aparcado, daños y fuga sin identificar al causante.
- 4 Cambio de carril con roce lateral y versiones opuestas.
- 5 Conductor bajo los efectos del alcohol y lesiones graves.

Ninguno de los cinco se responde con una búsqueda semántica. Los cinco exigen decidir si el Convenio aplica, y sólo entonces quién responde.

En cuatro de los cinco casos, la respuesta correcta del manual es no concluir.

Resueltos a mano contra el manual y verificados después contra el sistema en ejecución.

CASO DEL ENUNCIADO	VEREDICTO DEL SISTEMA	FUNDAMENTO EN EL MANUAL
1 Alcance en semáforo	Aplicable · culpa indeterminada	Faltan las casillas del apartado 12 de la D.A.A. que activan la tabla de culpabilidad · pág. 101
2 Colisión múltiple (5 vehículos)	Fuera del Convenio	Exige dos vehículos en colisión directa · pág. 56 — y excluye la colisión en cadena · pág. 57
3 Aparcado con daños y fuga	Indeterminado · condicionado	Sin identificar al causante no hay segunda parte: la norma del vehículo aparcado exige conocerla · pág. 73
4 Cambio de carril	Resuelto · ASCIDE b.10 · culpable A	Norma subsidiaria: si ambos reconocen el cambio de carril, responde quien lo efectúa · pág. 75 (orden de prioridad ASCIDE, pág. 111)
5 Alcohol y lesiones graves	Aplicable · culpa indeterminada	El alcohol no excluye el Convenio · pág. 9 — pero lesiones y vía penal quedan fuera de su alcance · págs. 27 y 62

Un asistente que resolviera los cinco estaría inventando cuatro. Esto no es una limitación del sistema: es lo que el manual sostiene, y el sistema llega ahí solo y con la cita delante.

Todo el sistema descansa sobre una sola regla: nada se afirma sin poder demostrarlo.

De ahí salen las tres garantías que atraviesan la arquitectura entera, y también las que la hacen más incómoda de construir.

1

EVIDENCIA

Cada afirmación arrastra su cita: documento, hash, página física del PDF y versión de extracción. Al pulsarla se abre el manual original por esa página.

2

DECISIÓN

El LLM interpreta el relato y rellena un vocabulario cerrado de hechos. Quien decide es un motor determinista sobre reglas firmadas. Nunca al revés.

3

ABSTENCIÓN

Si falta un hecho, el sistema dice cuál falta y por qué importa. La incertidumbre no se convierte en una responsabilidad atribuida.

Es lo único que separa un asistente demostrable de uno meramente convincente. Cuesta más construirlo; es la diferencia entre un piloto y un producto.

02

Plan, supuestos y riesgos

Cinco días, cinco hitos comprobables.
Ningún atajo que no esté escrito.

01 El problema

02 **Plan y riesgos**

03 Arquitectura

04 Demo en vivo

05 Evaluación y límites

Cinco días contruidos de abajo arriba: primero la evidencia, después la inteligencia.

Cada día cierra con un hito comprobable por un comando, no con una demostración. Si un día no cerraba, el siguiente no empezaba.



El mayor riesgo se mitigó el día uno: si el dominio hubiera resultado irreducible a reglas verificables, el sistema seguiría siendo útil como RAG documental con citas.

Seis supuestos declarados por escrito; ninguno escondido dentro del código.

Un supuesto que no se escribe acaba siendo una sorpresa en producción. Éstos están además en la documentación de entrega y en los metadatos del golden set.

- **El manual es la única fuente de verdad**

No se completa con derecho vigente ni con lo que el modelo crea recordar. Es la edición de noviembre de 2004.

- **Las casillas A0–A17 son externas al manual**

El apartado 12 de la declaración amistosa no está definido en el documento: vive en un catálogo aparte, versionado y validado.

- **El ámbito administrativo se da por bueno**

Matriculación española o del EEE y aseguradora adherida se asumen salvo que el relato diga lo contrario (art. 4, pág. 10).

- **Un solo usuario, entorno local**

Sin autenticación multiusuario ni alta disponibilidad: no es lo que la prueba evalúa, y fingirlo habría restado tiempo a lo que sí.

- **Ningún dato real de siniestros**

Todo el material es el manual público, los cinco casos del enunciado y casos sintéticos derivados del propio manual.

- **Lesiones y vía penal, fuera de alcance**

El Convenio regula daños materiales entre aseguradoras. El sistema lo declara en lugar de opinar (págs. 27 y 62).

Los seis se pueden discutir. Ése es el objetivo: un supuesto explícito es negociable, uno implícito es una avería esperando.

Los cinco riesgos que podían hundir esta prueba, y qué se hizo con cada uno.

Ninguno se cerró con «tener cuidado»: los cinco tienen una contramedida en el código o en el proceso, y se puede señalar dónde está.

RIESGO	IMPACTO	MITIGACIÓN APLICADA
El modelo alucina una responsabilidad	Crítico	La decisión no la emite el LLM. La emite un evaluador determinista sobre reglas firmadas, y una invariante del dominio impide publicar un culpable sin las reglas que lo sostienen.
La tabla 18×18 se transcribe mal	Crítico	324 celdas transcritas dos veces de forma independiente, comparadas por un comando y atestadas con firma. Una celda no conciliada no decide.
La cita no sostiene la afirmación	Alto	Los identificadores de evidencia apuntan al documento y a la página física, no al fragmento del índice. El visor abre el PDF original por esa página y el revisor juzga.
El golden set se ajusta al sistema	Alto	La referencia se construyó contra el manual, con revisión adversarial independiente y prohibiciones explícitas. El holdout se abre una sola vez, tras congelar código y prompts.
Cinco días para catorce reglas	Medio	Se priorizó la puerta de aplicabilidad completa y el patrón de una norma subsidiaria, luego replicado a seis más y a la tabla. La que falta se declara, no se disimula.

El patrón se repite: cada riesgo de generación se responde con una frontera de código, y cada riesgo de transcripción con una firma humana.

Seis decisiones técnicas, con el motivo y el precio que se pagó por cada una.

Una decisión sin coste declarado no es una decisión: es una preferencia. Éstas son las seis que más condicionan el resto del sistema.

DECISIÓN	POR QUÉ	COSTE ACEPTADO
Arquitectura hexagonal	El núcleo no puede depender de un SDK que cambia cada trimestre.	Más módulos y más ceremonia en el arranque.
LangGraph como adaptador, no como marco	La orquestación es un detalle: los casos de uso hablan con un puerto, no con el framework.	Renunciar a los atajos del framework dentro del dominio.
Reglas en un artefacto firmado, no en el código	Una regla debe poder revisarla una persona de negocio, versionarse y llevar firma.	Un lenguaje de predicados cerrado y deliberadamente corto.
Salida estructurada para extraer hechos	El modelo rellena un vocabulario cerrado; no redacta la conclusión.	Un prompt de extracción largo y muy acotado que hay que mantener.
Recuperación híbrida con fusión nativa	El manual mezcla lenguaje jurídico con referencias literales como «b.10» o «art. 35».	Dos representaciones del texto que mantener sincronizadas.
Langfuse autoalojado en vez de SaaS	Trazas, datasets y experimentos sin que salga un solo dato de la máquina.	Siete contenedores que operar en local.

Las seis comparten una intención: que dentro de seis meses se pueda cambiar el modelo, el índice o el orquestador sin volver a discutir quién responde en un alcance por detrás.

03

Arquitectura

Evidencia, orquestación y decisión como capas separadas.
Cambiar cualquiera de las tres sin tocar las otras dos.

01 El problema

02 Plan y riesgos

03 **Arquitectura**

04 Demo en vivo

05 Evaluación y límites

El núcleo de negocio no sabe que existen FastAPI, LangGraph, OpenAI ni Qdrant.

El dominio define el problema, la aplicación define los puertos, la infraestructura los implementa.

ADAPTADORES DE ENTRADA



```
grep -rE "fastapi|langgraph|openai|qdrant" backend/src/domain/ → 0 resultados. La frontera no es una intención de diseño: es comprobable.
```

Cada pieza del stack es reemplazable porque ninguna está en el centro.

La prueba de que la frontera es real no es el diagrama: es que dos parsers y dos índices ya conviven publicados sin que el dominio se haya enterado.

ORQUESTACIÓN

LangGraph

```
question_workflow  
claim_workflow  
query_workflow
```

Los casos de uso hablan con un puerto. Sustituir el orquestador no toca el dominio.

INGESTA

pypdf · Docling

```
document_parser  
evidence_repository
```

Dos parsers publicados a la vez para el mismo documento verificado.

RECUPERACIÓN

Qdrant híbrido

```
retriever  
index_publisher
```

Denso, BM25 y fusión son política del adaptador, no del caso de uso.

MODELOS

OpenAI

```
language_model  
claim_fact_extractor  
embedding_provider  
query_classifier
```

Cuatro puertos: generar, extraer, incrustar y clasificar no son la misma capacidad.

12 puertos de salida y 5 de entrada. Ninguna decisión del Convenio cambia si mañana se sustituye el proveedor de modelos, el índice o el orquestador.

El sistema usa un modelo para cuatro cosas distintas, y las trata como cuatro decisiones.

«Elegir el modelo» no es una decisión, son cuatro: cada uso tiene su exigencia, su coste y su frecuencia — y cada uno vive detrás de su propio puerto.

RESPONDER

Generación documental

OPENAI_ANSWER_MODEL

Redacta sólo sobre el contexto recuperado y con una cita por bloque. Es la llamada que más exige en calidad de escritura y respeto a la fuente.

EXTRAER

Hechos del siniestro

OPENAI_CLAIM_EXTRACTION_MODEL

Salida estructurada con esquema cerrado (extra="forbid", strict). No redacta la conclusión: rellena un vocabulario de hechos con nombre.

CLASIFICAR

Intención del usuario

ALLIANZ_ROUTER_MODEL

Tres etiquetas y nada más. Es la llamada más frecuente y la más barata: candidata natural a un modelo pequeño, o local.

INCRUSTAR

El manual, una sola vez

text-embedding-3-small
1536 dimensiones · coseno

Fijado en el perfil del índice y grabado en su firma de 13 campos: cambiarlo obliga a reindexar, y el sistema no deja hacerlo por accidente.

Y los prompts no se editan: se versionan. La configuración los fija por nombre y versión —document-question v1, auto-router v1—, así que cambiar un prompt es publicar una versión trazable, no una edición silenciosa.

Una sola conversación; tres recorridos deliberados y ninguno opaco.

El usuario puede elegir el recorrido o dejar que el sistema lo encamine. Lo que no puede pasar es que no sepa cuál se ha seguido.

1 MODO AUTOMÁTICO

por defecto

`classify → consulta | siniestro`

Un clasificador de salida cerrada decide el recorrido. Recibe el texto del usuario sin reescribirlo y nunca ve la respuesta esperada.

POST `/api/v1/queries/resolve`

2 CONSULTAR EL MANUAL

explícito

`retrieve → generate → validate`

Respuesta por bloques y cada bloque con su cita. Al pulsarla se abre el PDF original por la página que la sostiene.

POST `/api/v1/questions/answer`

3 ANALIZAR SINIESTRO

explícito

`extract → retrieve → apply_rules →
explain → validate`

Hechos atribuidos, reglas evaluadas —las que casan y las que no— y una decisión resuelta, condicionada o indeterminada.

POST `/api/v1/claims/analyze`

Los modos explícitos se saltan el router por completo: nadie queda a merced de una clasificación que no pidió.

La interfaz enseña el razonamiento, no sólo la respuesta.

Captura real resolviendo un cambio de carril: los hechos extraídos, las catorce reglas evaluadas y la decisión que resulta.

1 Los hechos, con su procedencia


vehicle_count, direct_collision, lane_change_vehicle... y cada uno dice de dónde sale: «según relato», «según ambos conductores». No hay un hecho sin origen.

2 Las catorce reglas, también las que no casan

Once dicen «no comprobable con los datos aportados». Esa ausencia es información: enseña exactamente qué haría falta para ir más lejos.

3 La decisión y la norma que la sostiene


ASCIDE · el Convenio es aplicable · resuelto, con el texto literal de la b.10. El modelo no ha redactado nada de esa conclusión.



Es la misma tarjeta que vería quien tramita el expediente: si discrepa de la conclusión, puede señalar el paso exacto — el hecho extraído, la regla aplicada o la redacción final.

La ingesta no «sube un PDF»: publica una versión inmutable del conocimiento.

Cinco pasos, y ninguno se puede saltar. Si el hash no coincide, la ingesta se rechaza antes de leer una sola página.

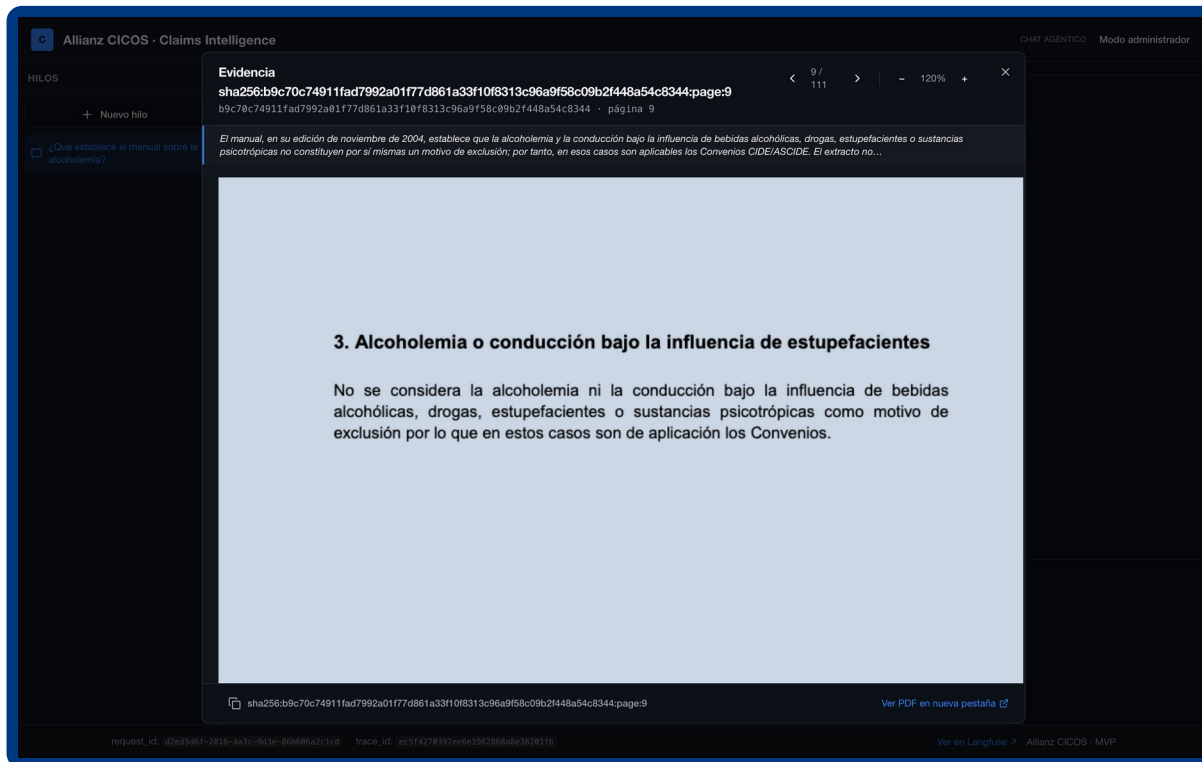


sha256:b9c70c74911fad7992a01f77d861a33f10f8313c96a9f58c09b2f448a54c8344 · 111 páginas · publicación atómica

El identificador de una evidencia es sha256:<documento>:page:<n>. Apunta al manual original, no al fragmento del índice: la cita sobrevive a cambiar de parser o de chunking.

Una cita no es una nota al pie: abre el manual por la página que la sostiene.

Captura real: la respuesta sobre alcoholemia cita la página 9 y, al pulsarla, aparece el párrafo exacto del manual original sin salir de la conversación.



- El identificador es del documento, no del fragmento

sha256:....:page:9. Sobrevive a reindexar con otro parser o con otro tamaño de chunk: la cita del golden set sigue siendo válida.

- Página física y etiqueta impresa, separadas

La 9 de 111 del PDF. La numeración que el manual imprime se guarda aparte cuando se conoce, porque no siempre coinciden.

- Sin coordenadas verificadas no se finge un resaltado

Con el perfil activo se abre la página entera. El perfil estructurado sí tiene las regiones para resaltar la frase — otra razón para compararlos.

Quien revisa no tiene que fiarse de la respuesta: tiene el manual delante en dos clics, y puede leer el párrafo entero, no el trozo que el sistema eligió enseñar.

Dos métodos de ingesta conviven publicados; sólo la evaluación decide cuál se activa.

Poder demostrar dos caminos de extracción sobre el mismo documento era un requisito propio: es la forma de que la elección deje de ser una opinión.

pypdf 6.16.2

BASELINE · ACTIVO EN DEMO

Texto plano por página y chunking de tamaño fijo con solapamiento.

- 118 fragmentos en el índice activo
- Reproducible y barato de reindexar
- Sin dependencias pesadas ni modelos de layout

Docling 2.124.0

ESTRUCTURADO · PUBLICADO, NO ACTIVO


Layout, Markdown y JSON originales, con chunking por secciones.

- 109 fragmentos, regiones verificadas en las 111 páginas
- Diagnóstico por página: tablas sin verificar, OCR ausente
- Coordenadas que permitirían resaltar la cita, no sólo abrir la página

Decisión consciente: que una técnica esté disponible no demuestra que mejore el resultado. El índice estructurado espera a la comparación de evaluación; el comando `compare-parsers` existe justo para eso.

Recuperación híbrida: la semántica encuentra el concepto, BM25 encuentra «b.10».

Este manual mezcla lenguaje jurídico con referencias literales. Una búsqueda sólo vectorial falla justo donde el documento es más útil.



dos señales sobre el mismo corpus, fusionadas sin reordenar a mano

Firma de índice de 13 campos

parser, chunker, modelo, dimensión, distancia, versión del documento...

El alias sólo se mueve si la firma encaja

promover un índice incompatible falla en vez de degradar en silencio


Rollback probado por comando

allianz index-rollback --collection ... devuelve el alias al índice anterior

Gobierno del índice: un índice no se activa porque exista, se activa porque su firma es compatible y su evaluación lo respalda.

El grafo documental es corto, tipado, y no entrega nada sin validarlo antes.

Tres nodos. La respuesta pasa por una comprobación contra el contexto recuperado antes de salir, y el estado que resulta viaja hasta la interfaz.




ESTADOS QUE LA INTERFAZ MUESTRA, SIN MAQUILLAR



Estado interno tipado, tiempo máximo acotado y traza en Langfuse bajo el session_id del hilo: la misma ejecución se puede auditar después.

El grafo de siniestros se interrumpe y pregunta antes que inventar.

Cinco nodos y una salida lateral: cuando falta un hecho que cambia la decisión, el grafo se detiene, pide ese dato concreto y reanuda el mismo hilo.



Preguntar por el dato que falta es una decisión del sistema, no un fallo: es la diferencia entre un asistente que colabora y uno que rellena huecos.

Del lenguaje natural a una decisión auditable, sin ningún salto mágico.


El modelo rellena un vocabulario cerrado de hechos. El motor evalúa predicados sobre esos hechos. Nadie más participa en la decisión.



El generador redacta la decisión; no la toma. No hay ningún camino en el código por el que una generación convierta un resultado indeterminado en definitivo.

La tabla de culpabilidad se transcribió dos veces a mano — por eso se puede confiar en ella.

324 celdas leídas de un PDF de 2004 en las que cada error es un error de atribución de responsabilidad. Ninguna se autotranscribió.



A2 + B4 — celda con observación impresa

Retícula ilustrativa; la transcripción real está firmada en el artefacto y se puede abrir.

- **324 celdas · 18 casillas A × 18 casillas B**
La tabla que el manual imprime en la página 101 para repartir responsabilidad a partir del apartado 12 de la declaración amistosa.
- **Doble transcripción independiente y adjudicación firmada**
Dos pasadas separadas, comparadas por comando (allianz rules compare-transcriptions) y atestadas. Una celda no conciliada no decide.
- **Las cuatro observaciones viven en el artefacto, no en el código**
Se declaran con campos propios —a qué celdas aplican, qué hecho las activa, sobre qué conductor y qué consecuencia tienen—. Una celda con asterisco sin observación anotada simplemente no decide.
- **Cuatro resultados que la interfaz no puede confundir**
Atribuye · no atribuye («-») · falta el hecho de la excepción · la excepción se cumple y retira la atribución.

Nunca se traduce una maniobra narrada a un código de casilla. Si el relato no declara «marcamos A2 y B4», la tabla no entra: inferirlo sería inventar el dato más determinante del expediente.

13 de las 14 reglas firmadas ya deciden; la que falta se declara, no se disimula.

Estado real del ruleset a día de hoy, comprobado sobre el artefacto: qué regla tiene condición verificable y cuál sigue siendo sólo documentación.

PUERTA DE APLICABILIDAD Y EXCEPCIONES

- | | |
|----------------------------------|--------------------------------------|
| ● cide-requires-two-vehicles | Dos vehículos intervinientes · p. 56 |
| ● cide-requires-direct-collision | Colisión directa entre ellos · p. 56 |
| ● third-vehicle-identified-... | Un tercero identificado lo excluye |
| ● chain-collision-excludes-... | Colisión en cadena excluida · p. 57 |
| ● alcohol-does-not-exclude-... | El alcohol no excluye · p. 9 |
| ● convention-scope | Ámbito: no es regla de decisión |

● Decide hoy ● Sin condición verificable ● No es regla de decisión

NORMAS SUBSIDIARIAS Y TABLA DE CULPABILIDAD

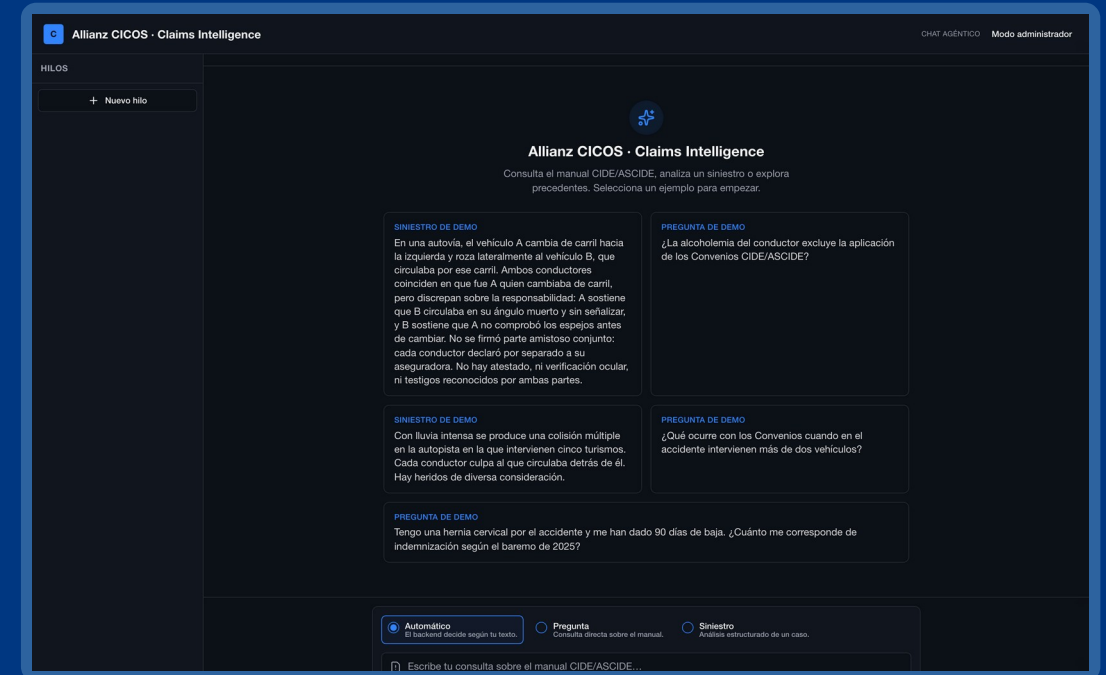
- | | |
|------------------------------------|------------------------------------|
| ● ascide-b5-parked-vehicle | Contra vehículo aparcado |
| ● ascide-b6-exit-from-parking | Salida de estacionamiento o garaje |
| ● ascide-b9-reverse-vs-rear-impact | Marcha atrás vs. alcance trasero |
| ● ascide-b10-lane-change | Cambio de carril · p. 75 |
| ● ascide-traffic-light-amber | Paso en ámbar admitido |
| ● cide-door-opening | Apertura de puertas sin precisar |
| ● cide-matrix-lookup | 324 celdas de la tabla · p. 101 |
| ● ascide-b11-roundabout | Rotondas · pendiente |

Falta b.11 (rotondas): su excepción no retira la atribución, la sustituye por otra — exige una segunda regla mutuamente excluyente, no rellenar un predicado. Mientras tanto devuelve insufficient_data de forma explícita, nunca como si hubiera casado.

04

Demo en vivo

Cuatro recorridos sobre el sistema real, en local.
Lo que hay que creerse no son las láminas.



01 El problema

02 Plan y riesgos

03 Arquitectura

04 Demo en vivo

05 Evaluación y límites

DEMO 1

Enrutado y consulta documental

«¿Qué establece el manual sobre la alcoholemia?»

QUÉ HAY QUE MIRAR

1

El modo se detecta solo

La interfaz declara «Consulta del manual» antes de responder. El usuario ve por qué recorrido va, siempre.

2

La respuesta llega por bloques

Y cada bloque trae su cita. No hay un párrafo con una bibliografía al final.

3

La cita abre el manual

Se pulsa y aparece el PDF original por la página 9, junto a la respuesta, sin salir de la conversación.

Es el recorrido más sencillo y ya enseña las tres garantías: recorrido explícito, cita por afirmación y evidencia alicable.

DEMO 2

El siniestro que sí se resuelve

Caso de demo accident-04-lane-change-es · cambio de carril con versiones opuestas

QUÉ HAY QUE MIRAR

1

Hechos extraídos, con atribución

lane_change_acknowledged_by_both, contradictory_versions, lane_change_vehicle — cada uno con el texto literal del relato que lo sostiene.

2

La tarjeta «Reglas evaluadas»

Enseña las que casan y también las que no casan, con el motivo. La ausencia de una regla es información.

3

Decisión: resuelto

Convenio aplicable · ASCIDE · responde el vehículo A, citando la norma subsidiaria b.10 en la página 75.

Éste es el único de los cinco casos del enunciado que se resuelve con lo que el propio relato aporta. Y se ve por qué.

DEMO 3

Abstenerse con criterio, y pedir el dato exacto

accident-02-pile-up-es · la tabla de culpabilidad con A2 + B4 · una pregunta fuera de alcance

QUÉ HAY QUE MIRAR

1

Fuera del Convenio, con fundamento

La colisión múltiple se declara no aplicable citando las páginas 56 y 57. No hay conclusión inventada ni un «depende».

2

La interrupción en directo

Con A2 y B4 declaradas, el sistema se detiene y pide el hecho de la observación impresa, con su texto literal.

3

Las dos ramas de la excepción

Si abre la puerta el conductor de B, responde B.
Si la abre el de A, la excepción retira la atribución y queda indeterminado — sin inventar quién paga.

Y la pregunta fuera de alcance: el sistema se abstiene sin dar cifras, en vez de improvisar un baremo que el manual no contiene.

DEMO 4

Trazabilidad y operación

Langfuse local · modo administrador de ingesta

QUÉ HAY QUE MIRAR

1

La traza de la ejecución que acaban de ver

Cada respuesta enlaza a su traza real. Nodos del grafo, llamadas al modelo, coste y latencia por etapa.

2

Un hilo, una sesión

El session_id agrupa todos los pasos de la misma conversación, incluida la interrupción y su reanudación.

3

Modo administrador

Hash verificado, 111 páginas, extracciones publicadas y previsualización paginada de lo que realmente se indexó.

La misma traza que mira quien opera el sistema es la que alimenta la evaluación. No hay una instrumentación para la demo y otra para producción.

05 Evaluación y límites

110 casos de referencia, un protocolo de medida y una lista explícita de lo que este sistema no hace.

01 El problema

02 Plan y riesgos

03 Arquitectura

04 Demo en vivo

05 Evaluación y límites

110 casos de referencia contruidos contra el manual, no contra el sistema.

El enunciado pedía «una evaluación básica de la calidad de las respuestas». La parte difícil no es medir: es tener una referencia en la que se pueda confiar.

110

casos admitidos

57 / 53

siniestros / consultas

105

en castellano

111

páginas en el pool de evidencia

5 accidentes del enunciado

Los que adjunta la prueba, resueltos a mano contra el manual. Son el criterio de aceptación, y están en el conjunto desde el primer día.

5 variantes en castellano

El siniestro que se resuelve, el que se excluye, dos consultas documentales y una pregunta que el sistema no debe responder.

100 casos sintéticos derivados del manual

Mitad consulta y mitad siniestro, cada uno anclado a páginas reales. Generados y después revisados de forma adversarial, no aceptados tal cual.

```
release synthetic-expansion-110-2026-09-03 · allianz golden validate → errors: [], item_count: 110
```

Cada caso se congela con firma: no se puede «mejorar» el golden después de ver los resultados sin que quede constancia de que se hizo.

Un caso golden no guarda una respuesta: guarda qué debe cumplirse y qué está prohibido.

Comparar cadenas de texto no mide nada en un dominio donde dos redacciones distintas pueden ser igual de correctas. Por eso la referencia es una especificación, no un texto modelo.

reference	La resolución razonada del caso, con las citas del manual que la sostienen paso a paso.	decisions	Aplicabilidad, convenio y decisión esperada: los tres ejes que un siniestro tiene que fijar.
requirements	Afirmaciones que la respuesta debe contener para considerarse correcta.	acceptable_alternatives	Redacciones distintas que también son correctas: evita penalizar la forma en lugar del fondo.
forbidden_facts	Lo que la respuesta no puede decir. Por ejemplo, presumir la culpa de quien alcanza por detrás.	evidence_requirements	Paquetes de evidencia AND/OR: qué páginas hay que citar, y cuáles son intercambiables entre sí.

CÓMO SE REVISÓ — Y QUÉ NO SE PUEDE AFIRMAR DE ESA REVISIÓN		
1 • Resolución ciega Cada caso se resuelve contra el manual sin ver la respuesta del sistema.	2 • Revisión adversarial Una segunda pasada independiente intenta tumbar la resolución y sus citas.	3 • Adjudicación Se concilian ambas y se anota el desacuerdo en los metadatos del caso.

Limitación declarada, no escondida: los tres pasos los hizo una IA. Ningún caso tiene todavía revisión de un experto humano del dominio, y eso consta en los metadatos de cada uno.

La evaluación está diseñada como un experimento, no como una captura de pantalla.

Lo que hace creíble a una métrica es el protocolo que la rodea: qué se mide, contra qué versión exacta, y qué está prohibido tocar.

QUÉ SE MIDE

- Corrección factual frente a la referencia
- Fidelidad de las citas: si la página sostiene la afirmación
- Acierto del enrutado entre consulta y siniestro
- Abstención correcta — la métrica que más importa aquí

CÓMO SE MIDE

- La release congelada se publica como dataset
- Un experimento por release, no ejecuciones sueltas
- Evaluadores deterministas antes que jueces LLM
- Cada ejecución identifica commit, hashes, perfil y modelos

QUÉ ESTÁ PROHIBIDO

- Ajustar el sistema mirando la reserva de holdout
- Retocar el golden después de ver los resultados
- Publicar una métrica sin la configuración que la produjo
- Activar un índice porque exista y no porque mida mejor

ESTADO REAL A DÍA DE HOY — sin adornos

Construido y comprobable ahora mismo: el golden de 110 casos (allianz golden validate → errors: [], item_count: 110), la release congelada con sus hashes y el ejecutor de experimentos sobre el recorrido documental.

- En curso: la campaña completa sobre los 110 casos, los evaluadores de siniestro y de enrutado, y publicar esta release como dataset en el proyecto de Langfuse en uso.
- Pendiente por decisión: congelar la reserva de holdout, que se abre una sola vez y todavía no toca.

Prefiero presentar el protocolo terminado y las métricas en curso, antes que un número redondo cuya procedencia no pueda defender delante de vosotros.

Cada ejecución deja huella: producto, modelo y evaluación miran la misma traza.

La observabilidad no se añadió para la demo. Es la misma instrumentación que alimenta los experimentos y la que permitiría investigar una queja real.

QUÉ SE TRAZA

- **Los tres workflows, nodo a nodo**
Documental, siniestros y enrutado automático, con su estado de entrada y salida.
- **Todas las llamadas al modelo**
Generación, extracción de hechos, clasificación y embeddings, con coste y latencia por etapa.
- **Un hilo, una sesión**
El session_id agrupa la conversación completa, incluida la interrupción y su reanudación.
- **Datasets y experimentos, junto a las trazas**
El mismo despliegue aloja los datasets de evaluación y sus ejecuciones: la medida no acaba en una hoja de cálculo aparte.

POR QUÉ AUTOALOJADO

Langfuse corre en local, con su propia base de datos, su almacén de objetos y su motor analítico.

Ni un relato de accidente ni una traza salen de la máquina. En un dominio donde el material de entrada son declaraciones de siniestro, esa propiedad no es un detalle de despliegue: es un requisito.

Y el mismo despliegue sirve para trazas, datasets y experimentos.

El enlace «Ver en Langfuse» de cada respuesta abre la traza real de esa ejecución concreta: «¿por qué contestó esto?» se responde con una traza, no con una conjetura.

Nada entra sin pasar cinco puertas, y las cinco están verdes hoy.

Ejecutadas sobre este repositorio antes de preparar esta presentación. Un solo comando las reproduce en local.

500

pruebas de backend

pytest · 1 omitida

97

pruebas de frontend

vitest · 17 ficheros

0

errores de tipado

pyright estricto + TS estricto

0

deriva de contrato

los tipos del cliente salen del
OpenAPI

0

avisos de linter

ruff + eslint

11.848 líneas en 111 módulos de backend

Módulos pequeños y con una responsabilidad: es lo que hace que un cambio de dominio no arrastre media aplicación.

51 módulos de frontend, tipos generados

React 19 con TypeScript estricto. Los DTO no se escriben dos veces: se generan del contrato que publica el backend.

El dominio se prueba sin red ni contenedores

Las reglas, la tabla de culpabilidad y las invariantes son funciones puras: sus pruebas corren en milisegundos.

make check reproduce las cinco puertas. Si una se cae, el trabajo no está terminado — da igual lo bien que se vea en pantalla.

Lo que este sistema no hace — dicho aquí, y no en la letra pequeña.

La misma disciplina que hace que el sistema se abstenga en un siniestro se aplica a cómo se presenta el sistema.

— No es derecho vigente

El manual es la edición de noviembre de 2004. El sistema responde lo que ese documento dice, no lo que hoy sea aplicable.

— No cubre lesiones ni vía penal

El Convenio regula daños materiales entre aseguradoras. Ante un baremo de lesiones el sistema se abstiene, sin dar cifras.

— No infiere las casillas de la declaración

Si el relato no declara qué marcaron los conductores en el apartado 12, la tabla de culpabilidad no entra. Deducirlo sería inventar el dato decisivo.

— No hay revisión de un experto humano

El golden set es una referencia sintética auditada contra el manual con revisión de IA en tres pasos. No es un baremo pericial.

— No hay todavía reserva de holdout

Los 110 casos están en desarrollo. La reserva se congela y se abre una sola vez, después de congelar código, prompts y reglas.

— Una de las catorce reglas sigue pendiente

b.11, rotondas. Devuelve `insufficient_data` de forma explícita, y el motivo técnico está documentado.

Ninguno de estos seis límites es una sorpresa de última hora: los seis están escritos en la documentación de entrega y, los que afectan al golden, en los metadatos de cada caso.

La siguiente iteración avanza por evidencia, no por disponibilidad.

Cuatro movimientos, en este orden. Ninguno exige tocar el dominio: es exactamente lo que la arquitectura tenía que comprar.

1

Cerrar la campaña de evaluación

Publicar métricas por recorrido sobre los 110 casos, con su commit y su configuración. Después, congelar la reserva de holdout.

2

Decidir el perfil de índice con datos

Comparar baseline y estructurado sobre el mismo golden. Si Docling gana, se promueve; si no, se queda publicado y sin activar.

3

Revisión humana experta del golden

Empezando por los cinco casos del enunciado. Es la limitación declarada más seria y la más barata de cerrar.

4

Completar b.11 y exponer el CLI de índices

La regla de rotondas como segunda regla mutuamente excluyente, y la gestión de índices desde el modo administrador.

El orden importa: primero medir, después promover. Invertirlo es cómo un sistema demostrable se convierte en uno que sólo parece bueno.

No es un chatbot sobre un PDF.

Es una plataforma RAG componible donde la evidencia, la orquestación y la decisión son capas independientes, observables e intercambiables — y donde abstenerse con criterio es una función del producto, no un fallo.

INGESTA

versionada y verificable

RECUPERACIÓN

híbrida y reversible

DECISIÓN

determinista y firmada

OPERACIÓN

trazable extremo a extremo

Gracias.

¿Preguntas?

A mano para las preguntas: docs/ESTADO.md (estado verificado) · el ruleset y la matriz firmados · la traza en Langfuse del caso resuelto · el golden set congelado

A

Apéndice

Material de apoyo para las preguntas: stack, API, glosario del dominio y comandos reproducibles.

01 El problema

02 Plan y riesgos

03 Arquitectura

04 Demo en vivo

05 Evaluación y límites

Las preguntas incómodas, con la respuesta corta y dónde está la larga.

« ¿Esto no lo está inventando el modelo? »	No: la decisión la emite un evaluador determinista sobre reglas firmadas, y una invariante del dominio impide publicar un culpable sin las reglas que lo sostienen.	Láminas 17 y 24
« ¿Por qué no resuelve los cinco accidentes? »	Porque el manual no da para más con los datos de cada relato. En cuanto el parte aporta las casillas del apartado 12, la tabla entra y resuelve.	Lámina 05 y demo 3
« ¿Qué métricas tenéis? »	El protocolo está terminado y la campaña completa está en curso. Prefiero enseñar la caja de estado real antes que un número que no pueda defender.	Lámina 35
« ¿Por qué no usáis Docling, si es mejor? »	Porque disponible no es lo mismo que mejor. Está publicado y esperando la comparación de evaluación que lo justifique; el comando para compararlos existe.	Lámina 20
« ¿Y si cambiáis de proveedor de modelo? »	Son cuatro puertos distintos: generar, extraer, clasificar e incrustar. El único que no se puede cambiar sin reindexar es el embedding, y la firma del índice lo impide.	Láminas 14 y 15
« ¿Esto no es sobreingeniería para cinco días? »	Costó tiempo el día 1 y lo devolvió el día 4, cuando hubo que meter la tabla de 324 celdas en el flujo sin romper nada de lo anterior.	Láminas 11 y 13
« ¿Quién ha validado el golden set? »	Una IA en tres pasos, documentados caso a caso. No un experto humano del dominio: es la limitación declarada más seria y la primera del roadmap.	Láminas 34 y 38

La regla para el turno de preguntas: si no lo puedo enseñar o citar, lo digo como pendiente. Nadie penaliza un límite declarado; todo el mundo penaliza uno descubierto.

Stack completo, y el puerto por el que cada pieza es sustituible.

Lenguaje y ejecución	Python 3.14 · uv	Entorno reproducible y resolución de dependencias rápida
API	FastAPI · Pydantic 2 · SSE	Contrato tipado y publicación del OpenAPI que consume el cliente
Orquestación	LangGraph · MemorySaver	Grafos tipados con checkpoint e interrupción humana
Modelos	OpenAI (generación, extracción, embeddings, enrutado)	Cuatro usos distintos tras cuatro puertos separados
Índice	Qdrant · denso + BM25 español (fastembed) · RRF nativo	Fusión determinista dentro del motor
Extracción de PDF	pypdf 6.16.2 · Docling 2.124.0	Dos perfiles publicados para el mismo documento verificado
Observabilidad y evaluación	Langfuse autoalojado · Ragas	Trazas, datasets, releases y experimentos en local
Cliente	React 19 · Vite · TypeScript estricto · pdfjs-dist	Tipos generados del OpenAPI; visor que rasteriza sólo la página visible
Calidad	pytest · vitest · pyright · ruff · eslint	Cinco puertas reproducibles con un comando

Superficie de API: un sobre común tipado para los tres recorridos.

CONVERSACIÓN

POST /api/v1/queries/resolve

Modo automático: clasifica y delega en el recorrido correcto

POST /api/v1/questions/answer

Consulta documental con citas; admite respuesta por SSE

POST /api/v1/claims/analyze

Análisis de siniestro; puede devolver una petición de datos

EVIDENCIA Y DEMO

GET /api/v1/evidence/{id}

Devuelve la evidencia por su identificador estable

GET /api/v1/demo/cases

Casos de demo, leídos del golden real sin exponer la respuesta esperada

GET /api/v1/manual/...

Inspección del manual publicado: páginas, extracciones y diagnósticos

ADMINISTRACIÓN Y SALUD

POST /api/v1/admin/ingest

Ingesta por API; sólo acepta el manual verificado por hash

GET /health/ready

Preparación real de dependencias, sin llamadas pagadas al modelo

GET /openapi.json

Contrato del que se generan los tipos del cliente

El sobre de respuesta es común a los tres recorridos: identifica el modo seguido, las etapas ejecutadas, las citas y el estado — por eso la interfaz enseña el razonamiento sin duplicar lógica.

Un solo contrato publicado en OpenAPI; los tipos del cliente se generan de él, y una comprobación falla si se separan.

Glosario mínimo del dominio, para que nadie asienta sin seguirlo.

CIDE

Convenio de Indemnización Directa Española. Reparto de responsabilidad entre aseguradoras a partir de la declaración amistosa firmada por ambos conductores.

ASCIDE

Acuerdo Suplementario al CIDE. Aporta la vía informatizada y las normas subsidiarias que resuelven supuestos concretos cuando las versiones no coinciden.

CICOS

Centro Informático de Compensación de Siniestros: la infraestructura común que liquida entre entidades adheridas.

D.A.A.

Declaración Amistosa de Accidente, el parte europeo. Su apartado 12 son las casillas que cada conductor marca describiendo su maniobra.

Casillas A0–A17 / B0–B17

Las dieciocho maniobras del apartado 12 para cada vehículo. Cruzarlas en la tabla de culpabilidad da 324 combinaciones.

Norma subsidiaria

Regla del ASCIDE que resuelve un supuesto típico —cambio de carril, marcha atrás, rotonda— cuando las declaraciones discrepan.

El manual es de noviembre de 2004 y estos convenios han evolucionado. El sistema responde lo que este documento dice, y lo declara.

Todo lo que se ha enseñado se reproduce con estos comandos.

ARRANQUE

```
make local-services-up
```

Qdrant, Langfuse, PostgreSQL, ClickHouse, Redis y MinIO

```
make serve-backend · make serve-frontend
```

API en :8000 y cliente en :5173

```
curl localhost:8000/health/ready
```

Comprobación de preparación antes de la demo

CALIDAD

```
make check
```

Las cinco puertas: pruebas, tipado, linter y contrato

```
make check-openapi
```

Verifica que el contrato y el cliente no se han separado

EVIDENCIA Y REGLAS

```
allianz compare-parsers
```

Compara la extracción de pypdf y de Docling sobre el mismo documento

```
allianz index-rollback --collection ...
```

Devuelve el alias activo al índice anterior, verificando la firma

```
allianz rules validate · compare-transcriptions
```

Valida el ruleset y concilia las dos transcripciones

EVALUACIÓN

```
allianz golden validate
```

errors: [], item_count: 110

```
allianz golden freeze · publish
```

Congela la release con sus hashes y la publica como dataset en Langfuse